

Monitoring&alerting model

Метрики можуть збиратися комплексно. Для бізнес-логіки та JVM: Spring Boot Actuator з використанням Micrometer. Для інфраструктури: агенти Node Exporter/cAdvisor на хостах. Усі дані збираються, зберігаються та візуалізуються через Prometheus та Grafana.

- Бізнес-метрики (recipe.generation.time, recipe.favorites.added.count): Збираються безпосередньо в коді Recipe Generation Module та Recipe Management Module за допомогою Micrometer Timers та Counters.
- Системні метрики (http.server.requests, jvm.memory.used): Збираються автоматично Spring Boot Actuator для всіх HTTP-запитів та JVM.
- Інфраструктурні метрики (system.cpu.usage, system.disk.usage): Збираються агентами Node Exporter, встановленими на віртуальних машинах/контейнерах, та передаються до Prometheus.

Метрика	Виміри	Зв'язок з інфраструктурними ресурсами	Призначення
1. recipe.generation.time	Мілісекунди (мс)	CPU, Network I/O (зовнішній API)	Час відповіді OpenAI.
2. http.server.requests (Response Time p95)	Мілісекунди (мс)	CPU, RAM, Network I/O	Час відповіді на API-запити (SLO: ≤ 500 мс).
3. circuitbreaker.state	Стан (OPEN/CLOSED/HALF_OPEN)	N/A	Стан Circuit Breaker для OpenAI API.
4. recipe.generation.failure.count	Кількість	N/A	Кількість збоїв викликів ШІ (5xx).
5. http.server.requests (Status 5xx Rate)	Відсоток (%)	N/A	Частота помилок на сервері.

6. <code>jvm.memory.used</code>	Мегабайти (МБ)	RAM	Використання пам'яті сервісом Spring Boot.
7. <code>system.cpu.usage</code>	Відсоток (%)	CPU	Загальне навантаження на процесор хоста.
8. <code>db.connection.active</code>	Кількість	RAM, Disk I/O	Кількість активних підключень до PostgreSQL.
9. <code>user.registration.count</code>	Кількість	Disk I/O (DB writes)	Кількість нових реєстрацій (бізнес-метрика).
10. <code>recipe.favorites.added.count</code>	Кількість	Disk I/O (DB writes)	Популярність функції "Улюблене".
11. <code>pdf.export.success.count</code>	Кількість	CPU (генерація), Disk I/O	Успішність роботи PDF Export Module .
12. <code>active.users.concurrent</code>	Кількість	CPU, RAM, DB Connections	Кількість одночасних користувачів (SLO: 1000, max 2000).
13. <code>process.uptime</code>	Секунди	N/A	Час безперебій

			ної роботи сервісу.
14. <code>system.disk.usage</code>	Відсоток (%)	Disk Space	Використання дискового простору резервні копії).

Alerts

Метрика	Мін/Макс Допустиме Значення	Тип	Критичність	Mitigation Plan
1. <code>recipe.generation.time</code>	Макс: 15 с (p95)	Threshold	Критична	1. Масштабування Spring Boot Backend (Recipe Generation Module). 2. Перевірка завантаження та лімітів OpenAI API. 3. Аналіз якості prompt для зменшення часу генерації.
2. <code>http.server.requests (Response Time p95)</code>	Макс: 500 мс	Threshold	Висока	1. Горизонтальне масштабування Spring Boot Backend. 2. Оптимізація повільних DB-запитів (R5.1). 3. Перевірка CPU/RAM на хостах.
3. <code>circuitbreaker.state</code>	Стан = OPEN	State Change	Критична	1. Перевірка доступності

	протягом 1 хв			OpenAI API. 2. Автоматичне/ручне скидання Circuit Breaker після підтвердження відновлення.
4. http.server.requests (Status 5xx Rate)	Середнє > 1% від загальної кількості запитів	Trend	Висока	1. Аналіз логів для виявлення причини 5xx (напр., R4.1 - помилка експорту PDF). 2. Можливий відкат (rollback) останнього розгортання.
5. db.connection.active	Макс: 90% від Max Pool Size	Threshold	Критична	1. Збільшення пулу підключень (Connection Pool Size). 2. Масштабування PostgreSQL (додавання Read Replicas). 3. Виявлення та завершення довготривалих транзакцій.
6. system.cpu.usage	Макс: 85% протягом 5 хв	Threshold	Висока	1. Горизонтальне масштабування Backend (автоскейлінг). 2. Виконання профілювання для виявлення "гарячих" точок коду.
7. jvm.memory.used	Макс: 80% від Heap	Threshold	Середня	1. Профілювання для виявлення Memory Leak. 2.

				Збільшення розміру Нерв.
--	--	--	--	-----------------------------